

Vorhersage des Bremsverhaltens für Robotersicherheit

Prediction of Stopping Behavior for Robot Safety

Hudson Smith^{1,2,3}, Nils Fatehpour^{1,2}, Björn Matthias¹, Debora Clever^{1,2}

¹ ABB AG, Forschungszentrum Deutschland

² Robotik-Systeme, Institut für mechatronische Systeme im Maschinenbau, TU Darmstadt

³ Virginia Polytechnic Institute and State University, Blacksburg, VA, USA

hudsonsmith@gmail.com, nils@fatehpour.de, debora.clever@de.abb.com, bjoern.matthias@de.abb.com

Kurzfassung

Ein zentraler Bestandteil der meisten Sicherheitskonzepte für robotergestützte Industriearbeitsplätze ist die Stoppfunktion des Manipulators. Um Informationen über das Bremsverhalten des Roboters online in einer Sicherheitsfunktion zu nutzen, muss diese robust gegenüber technischen Ausfällen sein. Ein typisches Implementierungsmerkmal ist diverse Redundanz. Da eine Untersuchung auf Basis unterschiedlicher Modellansätze den größten Wissensgewinn verspricht, verfolgen wir hier zwei separate Ansätze zur Vorhersage des Bremsverhaltens eines seriellen Manipulators. Wir betrachten ein physikalisch-empirisches Modell und ein aus Daten von tatsächlichen Stoppexperimenten erlerntes neuronales Netz, wobei der Fokus des Beitrags auf letzterem liegt. Die Güte der Vorhersage des Bremsverhaltens auf Basis des daten-basierten Modells wird analysiert, mit einem physikalisch-empirischen Modell verglichen und die Eignung der Ansätze zur Realisierung von diverser Redundanz diskutiert.

Abstract

A central component of most safety concepts for robot-based industrial workstations is the manipulator's stop function. In order to use information about the robot's stopping behavior online in a safety function, it must be robust against technical failures. A typical implementation feature is diverse redundancy. Since an investigation based on distinct model approaches promises the greatest gain in knowledge, we pursue two separate approaches for predicting the stopping behavior of a serial manipulator. We consider a physical-empirical model and a neural network trained on data of actual stopping experiments, with the focus of the article on the latter. The quality of the prediction of the braking behavior based on the data-driven approach is analyzed and compared with a physical-empirical model. The suitability of the approaches for the realization of diverse redundancy is discussed.

1 Einleitung

Aufgrund der Gefahren, die von sich bewegenden Maschinenteilen ausgehen, müssen Industrieroboter so eingesetzt werden, dass die Risiken für das Personal, das mit solchen Anlagen interagiert, vermieden, kontrolliert oder begrenzt werden. Dies wird durch internationale Normen zur Sicherheit von Industriearbeitsplätzen gefordert, die in fast allen Regionen der Welt befolgt werden, z.B. [1-4].

Ein zentraler Bestandteil der meisten Sicherheitskonzepte ist die Stoppfunktion von Roboterarmen. Das Bremsverhalten muss vor der Inbetriebnahme einer Roboteranwendung bekannt sein, da es eine Rolle bei der Verifizierung und Validierung der angewandten Risikominierungsmaßnahmen spielt.

Ein Beispiel für solche Maßnahmen ist die Platzierung eines Sicherheitszauns innerhalb des maximalen Arbeitsbereichs des Roboters, um Bodenfläche zu sparen, was eine Begrenzung der Manipulatorbewegung auf den Teilbereich innerhalb der Schutzvorrichtungen erfordert [5]. Jeder

Versuch, den Roboter außerhalb des eingeschränkten Arbeitsbereichs zu bewegen – sei es durch einen Fehler in der Steuerung oder einen Fehler im Anwendungsprogramm – muss eine Stoppfunktion auslösen, die den Roboter zum Stillstand bringt, bevor er ein Zaunelement erreicht.




Abbildung 1: Knickarmroboter IRB 1100 [15] zur Untersuchung des Bremsverhaltens (Traglast 4 kg, Reichweite 580 mm)

Im Bereich der kollaborativen Roboteranwendungen erfordert der Einsatz des Schutzkonzeptes „Geschwindigkeits- und Abstandsüberwachung“ die Online-Kennntnis des Bremsverhaltens des Roboter manipulators aus jedem Bewegungszustand. Die Risikominderung wird dadurch erreicht, dass der physische Kontakt zwischen dem menschlichen Bediener und den bewegten Teilen des Roboters verhindert wird [6]. Sobald der Abstand zwischen Bediener und Roboter eine Auslöseschwelle zu unterschreiten droht, muss eine Stoppfunktion eingeleitet werden.

Um Informationen über das Bremsverhalten des Roboters online in einer Sicherheitsfunktion zu nutzen, muss diese robust gegenüber technischen Ausfällen sein. Ein typisches Implementierungsmerkmal ist diverse Redundanz, d. h. die unabhängige Implementierung von zwei separaten Algorithmen, die dieselbe Information berechnen. Diese kann u.a. durch unterschiedliche Implementierung oder Kompilierung des gleichen Modells aber auch durch unterschiedliche Modellansätze erreicht werden. Datengetriebene oder physikalisch-motivierte Modelle sind Möglichkeiten.

Aus wissenschaftlicher Sicht verspricht die Untersuchung diverser Redundanz auf Basis unterschiedlicher Modellansätze den größten Wissensgewinn. Daher verfolgen wir zwei separate Ansätze zur Vorhersage des Bremsverhaltens eines seriellen Manipulators.

Eine zukünftige Perspektive besteht darin, diese beiden Ansätze in einer Sicherheitsfunktion zu verwenden, die Stoppzeiten und -wege für jeden beliebigen Bewegungszustand des Manipulators vorhersagt. Der Zustand ist dabei sowohl über Gelenkpositionen und -geschwindigkeiten, als auch weiterer anwendungsspezifischer Größen wie Traglast oder Stoppkategorie (gemäß [4]) spezifiziert. Die beiden Kanäle werden zum einen über ein physikalisch-empirisches Modell des Bremsverhaltens [7], [8] und zum anderen über ein neuronales Netz [9], [10] beschrieben, wobei zweiteres mit Daten von tatsächlichen Stoppexperimenten trainiert wird (Abbildung 2).




Abbildung 2: Schematische Darstellung des zweikanaligen Konzepts

Der hier vorgestellte Beitrag betrachtet hauptsächlich den datengetriebenen Kanal und nutzt hierfür physikalisches Vorwissen für das Design der Versuchsreihen und des neuronalen Netzes. Zur Vereinfachung werden nur die drei Hauptachsen eines Knickarmroboters mit sechs Freiheitsgraden bewegt und keine Nutzlast am Roboterflansch berücksichtigt. Zum Vergleich wird ein physikalisch motiviertes, parametrisches Modell für eine Achse an die Messdaten angepasst. In zukünftigen Arbeiten, aber nicht Teil

dieser Veröffentlichung, können die Ansätze dann auf den vollen Zustandsraum erweitert und ein zweikanaliges Sicherheitskonzept konkretisiert werden.

2 Vorarbeiten

Die Kenntnis von Anhaltewegen und -zeiten spielt eine wichtige Rolle in industriellen Robotersystemen und ist z.B. in der Norm ISO 10218-1 [1] geregelt. Nach Absatz 7.2 Punkt n) muss die Gebrauchsanweisung eines Roboters Angaben über das separate Bremsverhalten der drei Hauptachsen enthalten. Für die Stoppkategorie 0 sind Angaben für maximale Bedingungen (d.h. maximale Geschwindigkeit, Last und Auslenkung) ausreichend. Für Stoppkategorie 1 müssen i.d.R. zusätzliche Werte in Abhängigkeit von Geschwindigkeit, Last und Auslenkung für 33%, 66% und 100% der maximalen Werte angegeben werden.

Die Fokussierung des hier vorgestellten Ansatzes auf die drei Hauptachsen stellt daher keine Einschränkung im Vergleich zum Stand der Technik dar. Vielmehr berücksichtigt unser Ansatz sogar eine Erweiterung auf das Bremsverhalten für bis zu drei sich gleichzeitig bewegende Achsen.

Mindestens ein Hersteller bietet eine Sicherheitsfunktion an, welche die Bewegungsgeschwindigkeit derart angepasst drosselt, dass Wunschwerte für Anhalteweg oder Anhaltezeit eingehalten werden können. Wenn sich die Wunschwerte jedoch für optimale Produktivität ändern, lässt sich die Drosselung nicht dynamisch anpassen. Wir verfolgen eine Lösung, die durch sichere Abschätzung des instantanen Bremsverhaltens eine an optimale Produktivität angepasste Applikation ermöglicht.

Konkrete Vorarbeiten zur Verwendung eines neuronalen Netzes innerhalb einer Sicherheitsfunktion für die Vorhersage des Bremsverhaltens sind uns nicht bekannt. Losgelöst von datengetriebenen Ansätzen lassen sich Vorarbeiten zur Modellierung von Roboterbremsverhalten finden. Hierbei muss man unterschiedliche Stoppfunktionen separat betrachten.

Unkontrolliertes Stoppverhalten entspricht der Stoppkategorie 0 nach [4]. Dabei werden ausschließlich die mechanischen Bremsen genutzt und die Motoren werden zu Beginn der Anhaltebewegung abgeschaltet.

Beim geregelten Anhalten (Stoppkategorie 1 nach [4]) hingegen bleiben die Motoren während des Anhalteprozesses eingeschaltet und unterstützen diesen. Der Roboter folgt dabei einer vorgegebenen Anhalte-Trajektorie [11]. Hierzu kann beispielsweise ein Regler eingesetzt werden, der die Anhaltezeit minimiert und dabei die Limits der Motoren beachtet sowie ein simultanes Erreichen des Stillstands aller Achsen sicherstellt [12].

Eine weitere Möglichkeit ist das geregelte Anhalten entlang der geplanten Bahn, bei dem das Bewegungsincrement von der aktuellen zur nächsten programmierten Pose mit einem Faktor skaliert wird und somit eine kartesische Bremsrampe erzeugt wird [8].

Unabhängig von der speziellen Anwendung der Vorhersage des Bremsverhaltens gibt es zahlreiche Vorarbeiten, die das (teils dynamische) Roboterverhalten über

datengetriebene Ansätze modellieren. Zu nennen sind hier neuronale Netze, die für die Simulation der direkten und inversen Kinematik genutzt werden [13], sowie physikalisch basierte neuronale Netze für die Schätzung der dynamischen Parameter und Vorhersage der Dynamik der Roboterelkenke [14].

3 Stoppexperimente

Trotz unterschiedlicher Konzepte berücksichtigen sowohl das physikalisch motivierte empirische Modell wie auch das datenbetriebene Modell die Struktur des Manipulators. Im datengetriebenen Ansatz ergibt sich daraus die Auswahl geeigneter Versuche zur Erzeugung von Trainingsdaten und die Herleitung geeigneter Netzstrukturen.

Damit sich eine Überwachungsfunktion in sicherer Technik implementieren lässt, muss die Komplexität gering bleiben und alle relevanten Größen in der Sicherheitssteuerung zur Verfügung stehen. Insbesondere für kontrolliertes Anhalten entlang der geplanten Bahn (TCP-Trajektorie) bräuchte die Sicherheitssteuerung Informationen über die Bahnplanung, die üblicherweise dort nicht zur Verfügung steht. Wir fokussieren uns daher im Folgenden auf die Modellierung des Bremsverhaltens im Gelenkwinkelraum.

3.1 Beschreibungsgrößen

Ein Bremsvorgang beginnt mit dem Auslösen einer Stoppfunktion in der Steuerung zum Zeitpunkt t_0 . Während der Reaktionszeit t_r (Größenordnung 100 ms) setzt der Roboter die Fahrt zuerst ungebremst fort. Bei $t_1 = t_0 + t_r$ beginnt das Anhalten. Nach der Dauer der Bremsrampe t_p ist bei $t_2 = t_1 + t_p$ der Roboter im Stillstand (Abbildung 3).




Abbildung 3: Beschreibungsgrößen des Bremsvorgangs

Im Gelenkwinkelraum bezeichnen wir die Winkel des Gelenks k (Achse k) mit q_k und dessen Winkelgeschwindigkeit mit $\dot{q}_k = dq_k/dt$. Weiterhin sind $q_k^{(i)} := q_k(t_0)$ die Gelenkwinkel zum Zeitpunkt des Stopptriggers und $q_k^{(f)} := q_k(t_2)$ die Gelenkwinkel zum Zeitpunkt des Stillstands, für die Gelenkwinkelgeschwindigkeiten entsprechend. Im Weiteren werden die Gelenkindizes zur Vereinfachung der Notation teilweise vernachlässigt.

3.2 Experimentelles Vorgehen

Für unsere Arbeiten verwenden wir einen ABB IRB 1100 Knickarmroboter mit einer C30 Steuerung und der Steuerungssoftware RobotWare 7.7.1 [15],[16]. Das Anwenderprogramm in der ABB-Sprache RAPID initiiert die Roboterbewegung, triggert den Stoppbefehl, misst die relevanten Größen und speichert die Daten. Verwendet wird eine geregelte Stoppfunktion, die durch den RAPID-Befehl **StopMove** ausgelöst wird [17]. Es lassen sich längere Messreihen automatisiert aufnehmen.

Stoppbefehle werden ausgelöst bei vorab einstellbaren Triggerbedingungen aus Kombinationen von Gelenkwinkeln $q^{(tr)}$ und Gelenkgeschwindigkeiten $\dot{q}^{(tr)}$. Für jeden Stoppversuch werden die gemessenen Größen $q^{(i)}$, $\dot{q}^{(i)}$, $q^{(f)}$, t_r und t_p aufgezeichnet, wobei $q^{(i)} \approx q^{(tr)}$ und $\dot{q}^{(i)} \approx \dot{q}^{(tr)}$. So aufgezeichnete Daten liefern sowohl die Validierung für die Modellansätze im Folgenden als auch Trainings- und Testdatensätze für das datenbasierte Modell.

Für einen überschaubaren Parameterraum betrachten wir hier nur Bewegungen in den drei Hauptachsen (d.h. $q_n \equiv 0$, $\dot{q}_n \equiv 0$; $n = 4, 5, 6$), berücksichtigen nicht den Einfluss der Traglast und beschränken uns auf positive Gelenkwinkelgeschwindigkeiten ($\dot{q}_m^{(tr)} > 0$; $m = 1, 2, 3$).

3.3 Datenaufnahme

Um die Anzahl der Stoppexperimente zu minimieren werden Symmetrien berücksichtigt. Wichtig ist die vermutete Unabhängigkeit des Bremsverhaltens von der Position der ersten Achse sowie von ihrer Bewegungsrichtung, da der Roboter aufrecht montiert ist und Achse 1 nicht von der Schwerkraft belastet wird. Die experimentelle Überprüfung dieser Annahmen ist in Abbildung 4 für den Einfluss von $\dot{q}_1(t_0)$ auf den Anhalteweg (links) und die Anhaltezeit (rechts) dargestellt.




Abbildung 4: Symmetrie des Bremsverhalten in Achse 1

Somit werden in den hier betrachteten Versuchen nur Daten aufgezeichnet, für die $\dot{q}_1^{(tr)} = 0$ gilt und $\dot{q}_1^{(tr)}$ zuvor definierte positive Werte annimmt. Bei den anderen beiden Hauptachsen werden Positionen und Geschwindigkeiten gleichverteilt entlang des jeweiligen Definitionsbereichs gewählt (Tabelle 1).

Das Datenaufnahmeprogramm bildet aus den Werten in Tabelle 1 jede der 10'584 Kombinationen und führt zu jeder drei Stoppversuche durch (31'752 Versuche).

Tabelle 1: Parametersatz $\mathcal{D}_T$ – Trainings- und Testdaten

Achse k	Gelenkwinkel $q_k^{(tr)} [deg]$	Gelenkgeschwindigkeit $\dot{q}_k^{(tr)} [deg/s]$
1	[0]	[0, 40, 80, 120, 160, 200]
2	[-25, -20, -15, -10, 0, 5, 10]	[0, 20, 40, 60, 80, 95]
3	[-45, -40, -30, -20, -10, 0, 5]	[0, 10, 30, 50, 70, 90]

Weitere 13'500 Experimente bei 4'500 anderen Triggerbedingungen (Tabelle 2) wurden eigens für die Modellvalidierung durchgeführt. Diese Daten gehen nicht in den Trainingsprozess ein. Schließlich geben weitere 3×350 Versuche die Referenzdaten für die Darstellung der Modellvorhersage für Achse 1.

Tabelle 2: Parametersatz $\mathcal{D}_V$ – Validierungsdaten

Achse k	Gelenkwinkel $q_k^{(tr)} [deg]$	Gelenkgeschwindigkeit $\dot{q}_k^{(tr)} [deg/s]$
1	[0]	[20, 60, 100, 140, 180]
2	[-22.5, -17.5, -12.5, -5, 2.5, 7.5]	[10, 30, 50, 70, 87.5]
3	[-42.5, -35, -25, -15, -5, 2.5]	[5, 20, 40, 60, 80]

Für jeden Versuch wird die Bewegungstrajektorie berechnet und ausgeführt, damit beim Erreichen der Triggerwinkel $q^{(tr)}$ auch die gewünschte Geschwindigkeit $\dot{q}^{(tr)}$ erreicht ist. Nachdem die Stoppfunktion ausgelöst ist, wird der Beginn der Bremsrampe durch Eintritt einer ersten signifikanten Verringerung der Geschwindigkeit bei potenziell verrauschten Daten bestimmt. Der angehaltene Zustand des Roboters wird dann festgestellt, wenn die Restgeschwindigkeit unter 0.1 deg/s fällt, was bei ausgestrecktem Manipulator einer kartesischen Geschwindigkeit von unter 1 mm/s entspricht.

Die Stoppexperimente lassen sich mit demselben Programm auch in der ABB Simulationsumgebung RobotStudio [18] ausführen, wobei das simulierte Verhalten für gezielte Stoppfunktionen nur wenig vom experimentellen Verhalten abweicht.

4 Modelle des Bremsverhaltens

Ziel der Modellierung ist die Vorhersage der Stoppzeit (Anhaltezeit) $t_s = t_r + t_p$ und der Stoppdistanzen (Anhaltewege) $d_k = q_k^{(f)} - q_k^{(i)}$ bei gegebenen $q_k^{(i)}$ und $\dot{q}_k^{(i)}$. Während die Reaktionszeit t_r sich aus dem Verhalten des Steuerungsbetriebssystems und der Bremsrampenplanung zusammensetzt, ist die Dauer der Bremsrampe t_p eine Funktion von $q^{(i)}$ und $\dot{q}^{(i)}$.

Hier beschreiben wir näher die Modellvarianten der empirischen Betrachtung und der datengetriebenen Perspektive.

4.1 Physikalisch-Empirisches Modell

Da wir eine gezielte Stoppfunktion untersuchen ist das Bremsverhalten des Roboterarms nicht durch die freie Dynamik der Knickarmstruktur bestimmt, sondern durch das Regelgesetz der Steuerung.

Das physikalisch-empirische Modell wird nur für den Fall eines Stopps des ersten Gelenks betrachtet, die weiteren

Gelenkwinkel bleiben jeweils konstant bei 0°. Modelle mit Berücksichtigung mehrerer Freiheitsgrade sind aktuell noch in der Entwicklung.

Für das Modell wird angenommen, dass der Roboter einer Referenztrajektorie perfekt folgt. Diese ähnelt der in Abbildung 3 gezeigten Verläufe mit dem Unterschied, dass der Ruck betragsmäßig auf den Wert j_{max} begrenzt wird. Während des Bremsvorgangs werden die Gelenke mit konstanter negativer Beschleunigung $-a_{max}$ bis zum Stillstand gebremst. In Experimenten hat sich gezeigt, dass a_{max} von $\dot{q}^{(i)}$ abhängt und linear angenähert werden kann:

$$a_{max} = c_1 \dot{q}^{(i)} + c_0; \quad c_0, c_1 \in \mathbb{R}$$

Das physikalisch-empirische Modell kann folglich in vier Phasen unterteilt werden.

1. Das Gelenk dreht mit konstanter Geschwindigkeit $\dot{q} = \dot{q}^{(i)}$ für den Zeitraum $t_0 < t < t_1$
2. Die Beschleunigung sinkt linear (Steigung = $-j_{max}$) bis $-a_{max}$ erreicht wird
3. Die Beschleunigung bleibt bis kurz vor dem Stillstand konstant auf dem Wert $-a_{max}$
4. Die Beschleunigung steigt linear (Steigung = j_{max}) und erreicht den Wert 0 beim Zeitpunkt $t = t_2$

Aus den vier Phasen lassen sich die Stoppdistanz und die Stoppzeit für gegebene Parameter c_0, c_1, j_{max} und t_r für beliebige $\dot{q}^{(i)}$ berechnen.

$$d = \frac{1}{2} \dot{q}^{(i)} \left(\frac{\dot{q}^{(i)}}{a_{max}} + 2t_r + \frac{a_{max}}{j_{max}} \right)$$

$$t_s = \frac{\dot{q}^{(i)}}{a_{max}} + t_r + \frac{a_{max}}{j_{max}}$$

Die Parameter werden mithilfe der für das datenbasierte Modell aufgenommen Trainingsdaten bestimmt.

4.2 Datenbasiertes Modell

Das Bremsverhalten des Roboters wird bestimmt durch die Gelenkwinkel $q^{(i)}$ und -geschwindigkeiten $\dot{q}^{(i)}$ zum Zeitpunkt des Auslösens eines Stopps, sowie durch die spezifischen Eigenschaften der verwendeten Stoppfunktion. Für einen sechssachsigen Roboter sind daher die relevanten Eingangsparameter für ein neuronales Netz die 12 Größen $[q^{(i)}, \dot{q}^{(i)}]$. Das Netz soll bei diesen Eingaben die 8 Größen $[q^{(f)}, t_r, t_p]$ ausgeben. Die Trainings- und Testdaten der durch Tabelle 1 definierten 31'752 Stoppexperimente bestehen aus den Messdatentupeln $\{[q^{(i)}, \dot{q}^{(i)}]; [q^{(f)}, t_r, t_p]\}$.

Zum Anlernen eines neuronalen Netzes mittels der Trainingsdaten wird eine auf PyTorch [19], [20] aufbauende Lernumgebung implementiert. Anhaltezeiten und Anhaltewege unterscheiden sich in ihrer Varianz, aber auch in ihren physikalischen Einheiten und der Skalierung, was den Einsatz von separaten oder schwach verknüpften Netzen mit einer unterschiedlichen Anzahl an Schichten motiviert.

Die Struktur des zweischichtigen Modells zusammen mit den betrachteten Ein- und Ausgangsgrößen ist in

Abbildung 5 dargestellt. Die Wahl der Hyperparameter ist in Tabelle 3 zusammengefasst.




Abbildung 5: Struktur des trainierten neuronalen Netzes

Der erste Block des Netzmodells bildet die Eingangsdaten $[q^{(i)}, \dot{q}^{(i)}]$ auf die Gelenkwinkel nach dem Stopp $q^{(f)}$ ab. Der zweite Block verwendet dieses Ergebnis, um die Reaktionszeit t_r und Bremsrampendauer t_p auszugeben.

Zu Beginn werden die nach Tabelle 1 aufgenommenen Daten auf ihre Werteintervalle normiert, so dass diese numerische Werte zwischen -1 und +1 annehmen. Dann wird der normierte Datensatz in 80% Trainings- und 20% Testdaten aufgesplittet und erstere in Batches zur Verwendung in PyTorch unterteilt.

Tabelle 3: Hyperparameter und Ansätze des neuronalen Netzes

Parameter	Distanzen	Zeiten	Ansatz	
Learning Rate	10^{-4}	10^{-2}	Loss Function	MSEloss
Batch Size	15	30	Optimizer	ADAM
Input nodes	12	18	Activation Function	Sigmoid
Hidden layers	15,10,10	20,15,15	Layer Type	Linear
Output nodes	6	2		

Das Netz wird über eine vordefinierte Anzahl von Epochen trainiert. Konvergenz wird anhand einer „MSE-loss function“, also auf Basis der mittleren Fehlerquadrate (mean-squared-error), beurteilt.

Da das Bremsverhalten des Roboters von der verwendeten Stoppfunktion abhängt – insbesondere gibt es wesentliche Unterschiede zwischen geregelten und ungeregelten Stoppfunktionen – ist im Allgemeinen ein trainiertes neuronales Netz nur für die bei den Trainings- und Testdaten verwendete Stoppfunktion gültig.

5 Resultate

Konvergenz des Lernprozesses kann nach ca. 50 Epochen sowohl für Anhaltewege als auch für Anhaltezeiten beobachtet werden (Abbildung 6).




Abbildung 6: Verlustfunktion (loss function) in den drei Hauptachsen beim Lernen von Distanzen (links) und Zeiten (rechts)

Die trainierten Teilnetze beschreiben die Abbildungen

$$\begin{aligned} \mathcal{S}_d: (q^{(i)}; \dot{q}^{(i)}) &\mapsto q^{(f)}, \quad d = q^{(f)} - q^{(i)} \\ \mathcal{S}_t: (q^{(i)}; \dot{q}^{(i)}; q^{(f)}) &\mapsto (t_s, t_p). \end{aligned}$$

Die Teilnetze $\mathcal{S}_d$ und $\mathcal{S}_t$, sowie das Gesamtnetz $\mathcal{S} = \mathcal{S}_t \circ \mathcal{S}_d$ können für jede beliebige Stoppkonfiguration $(q^{(i)}; \dot{q}^{(i)})$ ausgewertet werden.

5.1 Netzvorhersagen

Abbildung 7 zeigt die Vorhersagen des für alle Hauptachsen trainierten Netzes beispielhaft für Achse 1 (durchgezogene Linien), links die Auswertungen der Anhaltewege

$$\begin{aligned} d_1 &:= q_1^{(f)} - q_1^{(i)}, \quad q_1^{(i)} = 0, \\ (q_1^{(f)}, \dots, q_6^{(f)}) &= \mathcal{S}_d(0,0,0,0,0,0; \dot{q}_1^{(i)}, 0,0,0,0,0), \end{aligned}$$

und rechts die jeweiligen Anhaltezeiten t_s und t_p , mit

$$(t_s, t_p) = \mathcal{S}_t(0,0,0,0,0,0; \dot{q}_1^{(i)}, 0,0,0,0,0; q_1^{(f)}, 0,0,0,0,0).$$

Zum Vergleich sind die speziell für Achse 1 aufgenommenen Referenzdaten (Punkte) aufgetragen.




Abbildung 7: Vorhersage der Anhaltewege und -zeiten

Die vertikalen blauen Linien zeigen die Lage der im Trainingsvorgang verwendeten Werte von $\dot{q}_1^{(i)}$.

5.2 Validierung

Um eine generelle Aussage über die Güte des gelernten Netzes zu geben, wird die Auswertung des Netzes mit den gemäß Tabelle 2 eigens für diesen Zweck ermittelten Validierungsdaten verglichen.

Anders als die fein aufgelösten Referenzdaten für Achse 1 beinhaltet das Validierungsdatenset Kombinationen aller Achsen, jedoch in einer viel größeren Auflösung. Der Vergleich von gemessenen Anhaltewege und -zeiten mit entsprechenden Auswertungen des neuronalen Netzes erlaubt eine quantitative Aussage zur Güte des Netzes für drei Achsen, den jeweiligen Winkelbereich und die betrachteten Geschwindigkeiten.

Zunächst wird die Güte des Netzes evaluiert, wenn sich die Validierungsdaten im gleichen Definitionsbereich befinden, wie die Trainingsdaten (Interpolation). Dann wird betrachtet, inwieweit sich das datengetriebene Model eignet, um das Bremsverhalten für Konfigurationen außerhalb des Definitionsbereichs der Trainingsdaten vorherzusagen (Extrapolation).

5.2.1 Interpolation

Im Folgenden wird der „root-mean-squared-error“ (RMSE) zwischen aufgezeichneten Daten und der Auswertung des Netzes in gleicher Konfiguration als Maß für die Güte verwendet. Für die separierte Netzstruktur wird zwischen dem RMSE der Anhaltewege und dem der Anhaltezeiten unterschieden. Die Güte des Netzes zur Approximation von Trainings- und Testdaten ist in den ersten beiden Spalten von Tabelle 4 gegeben.

Tabelle 4: Approximationsgüte Interpolation

RMSE für:	Trainingsdaten	Testdaten	Validierungsdaten
Distanz	0.90 deg	0.90 deg	0.75 deg
Zeit	13 ms	13 ms	14 ms

Da erstere für das Training und zweitere für das Abbruchkriterium verwendet werden, sind die verhältnismäßig niedrigen Werte wenig überraschend. Die Werte in der dritten Spalte zeigen die Approximationsgüte für den Validierungsdatensatz (Tabelle 2). Hier lässt sich eine hohe Approximationsgüte auch für unbekannte Konfigurationen innerhalb des Definitionsbereichs der Trainingsdaten $\mathcal{D}_T$ beobachten. Dass der RMSE in den Distanzen sogar leicht niedriger ausfällt, ist darauf zurückzuführen, dass die Validierungsdaten keine Kombinationen mit stillstehenden Hauptachsen enthalten, die vom Netz in der Regel schlechter approximiert werden.

5.2.2 Extrapolation

Um die Extrapolationseigenschaften für Gelenkpositionen außerhalb des Trainingsbereichs zu analysieren, wird ein Netz $\mathcal{S}_{subpos}$ auf einer Untermenge der Trainings- und Testdaten angelernt (Tabelle 5). Hierbei werden die Positionen an den unteren und oberen Intervallgrenzen von $\mathcal{D}_T$ exkludiert.

Tabelle 5: Parameterbereiche für Trainingsdaten $\mathcal{D}_{subpos}$ für Netz $\mathcal{S}_{subpos}$

Achse k	Gelenkwinkel $q_k^{(tr)}$ [deg]	Gelenkgeschwindigkeit $\dot{q}_k^{(tr)}$ [deg/s]
1	[0]	[0, 40, 80, 120, 160, 200]
2	[-20, -15, -10, 0, 5]	[0, 20, 40, 60, 80, 95]
3	[-40, -30, -20, -5, 0]	[0, 10, 30, 50, 70, 90]

Die Approximationsgüte von $\mathcal{S}_{subpos}$ für Konfigurationen dieser Untermenge entspricht der des Netzes für den Gesamtdatensatz (vergleiche Spalte 1 und Spalte 2 in Tabelle 4 und Tabelle 6).

Tabelle 6: Approximationsgüte Extrapolation in Positionen

RMSE für:	Trainingsdaten	Testdaten	Validierungsdaten
Distanz	0.96 deg	1.0 deg	1.7 deg
Zeit	12 ms	12 ms	18 ms

Anschließend wird das Netz für die Konfigurationen der Validierungsdaten ausgewertet und mit dem experimentell ermittelten Bremsverhalten verglichen (Tabelle 6, Spalte

3). Wie erwartet sinkt die Approximationsgüte beim Extrapolieren signifikant ab, was den bekannten Nachteil von daten-getriebenen Modellen belegt.

Auf ähnliche Weise lassen sich auch die Extrapolationseigenschaften hinsichtlich der Gelenkgeschwindigkeiten analysieren. Hier wird ein Netz $\mathcal{S}_{subvel}$ trainiert (Tabelle 7).

Tabelle 7: Parameterbereiche für Trainingsdaten $\mathcal{D}_{subvel}$ für Netz $\mathcal{S}_{subvel}$

Achse k	Gelenkwinkel $q_k^{(tr)}$ [deg]	Gelenkgeschwindigkeit $\dot{q}_k^{(tr)}$ [deg/s]
1	[0]	[0, 80, 120, 160]
2	[-25, -20, -15, -10, 0, 5, 10]	[0, 40, 60, 80]
3	[-45, -40, -30, -20, -5, 0, 5]	[0, 30, 50, 70]

Hier sinkt die Approximationsgüte für Daten außerhalb des Trainingsbereichs ebenfalls signifikant ab (Tabelle 8).

Tabelle 8: Approximationsgüte Extrapolation in Geschwindigkeiten

RMSE für:	Trainingsdaten	Testdaten	Validierungsdaten
Distanz	1.4 deg	1.3 deg	2.7 deg
Zeit	13 ms	14 ms	19 ms

Vergleicht man die Auswertungen von $\mathcal{S}_{subvel}$ auf Achse 1 mit den entsprechenden Auswertungen von $\mathcal{S}$ so ist ein deutlicher Unterschied sowohl für die hohen als auch für die niedrigen Geschwindigkeiten zu beobachten.

6 Zusammenfassung und Ausblick auf Gesamtkonzept

Auch wenn das physikalisch-empirische Modell bisher nur für Bewegungen in einer Hauptachse definiert ist, so lassen sich für diese Teilmenge bereits erste Vergleiche zwischen den beiden Modellansätzen anstellen und deren Eignung zur Realisierung von diverser Redundanz als Sicherheitsfunktion diskutieren.

6.1 Vergleich von physikalisch motiviertem und datengetriebenem Modell

Vergleicht man anhand des „mean absolute error“ (MAE) die Resultate der beiden in Abschnitt 4.1 und Abschnitt 4.2 vorgestellten Modelle für den auf Achse 1 reduzierten Bewegungsraum des Knickarmroboters, so kann man für die Qualität der Vorhersage für Konfigurationen innerhalb des durch Daten untersuchten Bereiches (Interpolation) durchschnittliche Fehler in den Anhaltewegen von unter 1° und in den Anhaltezeiten von unter 10 ms beobachten (Tabelle 9, Spalte 1).

Betrachtet man dagegen die Güte der Vorhersage für unbekannte Konfigurationen, die außerhalb des untersuchten Bereichs liegen (Extrapolation) so sieht man vor allem für hohe Geschwindigkeiten signifikante Unterschiede zwischen den beiden Modellen.

Tabelle 9: Approximationsgüte der beiden Modelle auf Achse 1

MAE für:	Interpolation	Extrapolation (nied. Gesch.)	Extrapolation (hohe Gesch.)
Phys.-emp. Modell	0.83 deg 8.3 ms	0.16 deg 8.2 ms	2.7 deg 10 ms
Neuronales Netz	0.82 deg 8.1 ms	0.65 deg 12 ms	3.3 deg 20 ms

Den in Tabelle 9 angegebenen mittleren Fehlern liegen Wahrscheinlichkeitsverteilungen der Differenzen zwischen Modellen und Daten zugrunde. Die Eignung der Modelle als Kanäle einer Sicherheitsfunktion zur Vorhersage des Stoppverhaltens kann durch die Betrachtung der Überschneidung ihrer Wahrscheinlichkeitsverteilungen beurteilt werden.

6.2 Schlussfolgerung und nächste Schritte

In dieser Arbeit wurde nachgewiesen, dass zweckmäßig trainierte neuronale Netze dazu geeignet sind, das Stoppverhalten von Knickarmrobotern vorherzusagen. Wir haben dazu die gleichzeitige Bewegung der drei Hauptachsen betrachtet, was über heutige Normenanforderungen hinausgeht. Die beobachtete Genauigkeit reicht voraussichtlich für die Implementierung einer schnell auszuwertenden Funktion in einer Sicherheitssteuerung aus.

Zusammen mit den Vorhersagen eines physikalisch-empirischen Modells eröffnet sich die Perspektive auf eine zweikanalige Sicherheitsfunktion zur online-Vorhersage der Anhaltewege und -zeiten eines Knickarmroboters.

7 Danksagung

Die Autoren bedanken sich bei Dr. Andrea L'Afflito, Grado Department of Industrial and Systems Engineering, Virginia Tech, für die gute Zusammenarbeit bei der Betreuung einer diesem Beitrag zugrundeliegenden Masterarbeit.

8 Literatur

- [1] ISO 10218-1:2011, *Robots and robotic devices – Safety requirements for industrial robots – Part 1: Robots*, ISO, Geneva, 2011.
- [2] ISO 10218-2:2011, *Robots and robotic devices – Safety requirements for industrial robots – Part 2: Robot systems and integration*, ISO, Geneva, 2011.
- [3] ISO/TS 15066:2016, *Robots and robotic devices – Collaborative robots*, ISO, Geneva, 2016.
- [4] IEC 60204-1:2021, *Safety of Machinery – Part 1: General requirements*, IEC, Geneva, 2021.
- [5] T. Salmi, O. Väättäin, T. Malm, J. Montonen, *Safety challenges of transferable robotic systems*, in ROBOTIK 2012; 7th German Conference on Robotics, pp. 1–6, 2012.
- [6] C. Byner, B. Matthias, H. Ding, *Dynamic speed and separation monitoring for collaborative robot applications—concepts and performance*, Robotics and Computer-Integrated Manufacturing, 58, pp.239–252, 2019.
- [7] T. Dietz, A. Pott, A. Verl, *Simulation of the stopping behavior of industrial robots*, in New Trends in Mechanism Science, D. Pisla, M. Ceccarelli, M. Husty, and B. Corves, Eds., pp. 369–376, 2010.
- [8] F. Lange, M. Suppa, *Trajectory generation for immediate path-accurate jerk-limited stopping of industrial robots*, International Conference on Robotics and Automation (ICRA), pp. 2021–2026, 2015.
- [9] F. Cursi, D. Chappell, P. Kormushev, *Augmenting loss functions of feedforward neural networks with differential relationships for robot kinematic modeling*, in 2021 20th International Conference on Advanced Robotics (ICAR), pp. 201–207, 2021.
- [10] F. Cursi, W. Bai, W. Li, E. M. Yeatman, P. Kormushev, *Augmented neural network for full robot kinematic modelling in SE(3)*, IEEE Robotics and Automation Letters, vol. 7, no. 3, pp. 7140–7147, 2022.
- [11] N. Mansfeld, S. Haddadin, *A comparison of braking strategies for elastic joint robots*. Proceedings, IEEE International Conference on Robotics and Automation, 789–796, 2015.
- [12] M. Hamad, J. Gutierrez-Moreno, H.T.M. Kussaba, N. Mansfeld, S. Abdolshah, A. Swikir, W. Burgard, S. Haddadin, *Fast yet predictable braking manoeuvres for real-time robot control*, IFAC-Papers OnLine, 56(2):9984–91, 2023.
- [13] S. Garg, P. Singh, B. Gupta, R. Garg, *Manipulation of Standard Link Mechanism for Robotic Application Using Artificial Neural Network and PID*, 10.1007/978-981-16-0598-7_1, 2021.
- [14] X. Yang, Y. Du, L. Li, Z. Zhou, X. Zhang, *Physics-Informed Neural Network for Model Prediction and Dynamics Parameter Identification of Collaborative Robot Joints*, IEEE Robotics and Automation Letters, vol. 8, no. 12, pp. 8462–8469, 2023.
- [15] Product manual IRB 1100, <https://library.abb.com/d/3HAC064992-003> [Accessed 2024-01-19].
- [16] Product manual, OmniCore C30, <https://library.abb.com/d/3HAC060860-003> [Accessed 2024-01-19].
- [17] Technical reference manual - RAPID overview RW 7, <https://library.abb.com/d/3HAC065040-003> [Accessed 2024-01-19].
- [18] Operating manual - RobotStudio, <https://library.abb.com/d/3HAC032104-003> [Accessed 2024-01-19].
- [19] PyTorch library for deep learning applications, <https://pytorch.org> [Accessed 2024-01-19].
- [20] A. Paszke, S. Gross, F. Massa, et al., *Pytorch: An imperative style, high-performance deep learning library*, Advances in Neural Information Processing Systems 32, Curran Associates, Inc., pp. 8024–8035, 2019.